Algoritmos de Classificação

Árvores de Decisão

Árvores de Decisão

- Conhecimento adquirido pode ser representado em *linguagens* de alto nível
  - De forma legível e interpretável por humanos

- Motivações
  - Compreender um problema (mais do que obter modelos precisos)
  - Justificar decisões
  - Incorporar novo conhecimento

Árvores de Decisão

- Ampla classe de algoritmos de aprendizado
  - Exemplo: ID3, C4.5, CART,...

- Conhecimento representado em uma *árvore de decisão*, em geral, na linguagem da lógica de atributos

Árvores de Decisão

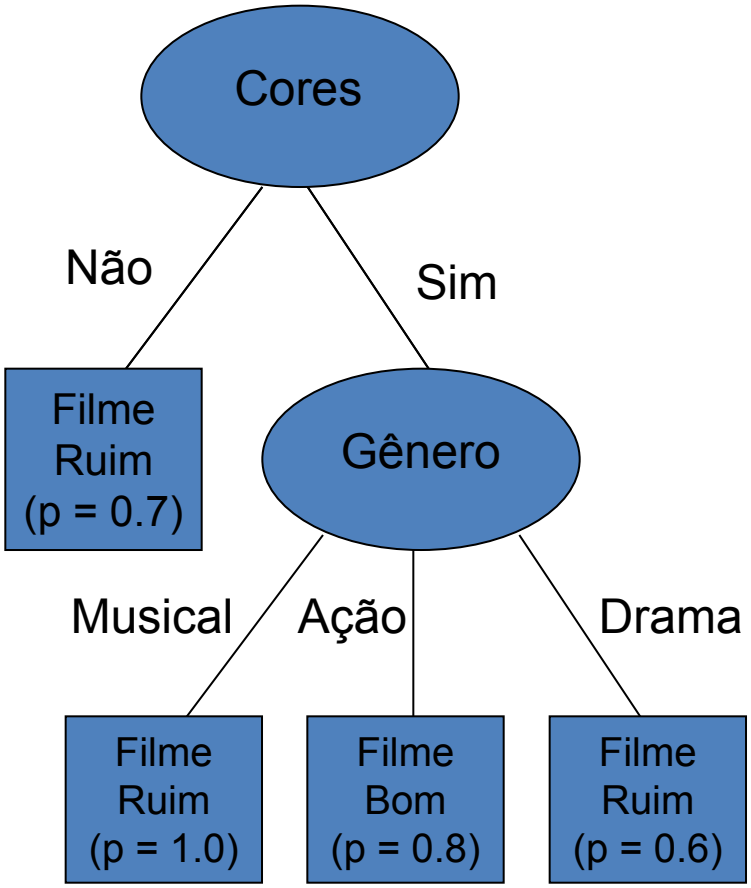

- Cada *nó interno* (*não-terminal*) contém um *teste* sobre os valores de um dado atributo
- *Folhas* da árvore (*nós terminais*) são associadas às classes
  - Comumente, acompanhadas com *graus de confiança*
- Novas instâncias classificadas percorrendo a árvore a partir da *raiz* até as folhas

Árvores de Decisão
- Construção

- Árvore de decisão construída de forma *recursiva* da raiz para as folhas (*top-down*)
  - A cada nó, é escolhido um *teste* que separe melhor os exemplos de classes diferentes
    - Maximização de *critério de separação*
  - Nós terminais são criados ao atingir um *critério de parada*
    - Ex.: todos os exemplos do nó pertencem à uma só classe

Árvores de Decisão
- Construção

- AD(Exemplos:D; Atributos:A; Alvo:C)
  - Crie nó_raiz
  - SE *Critério_de_Parada*

    ENTÃO Crie nó terminal associada à classe mais freqüente
  - SENÃO Encontre *atributo* a_j cujo *teste de decisão* maximize a *separação* dos exemplos que atingem o nó

    - PARA CADA *valor v* do teste adicione nova sub-árvore

      - Sub_arvore = AD($D_{[a_j = v]}$, A, C)

Árvores de Decisão – Critérios de Separação

- Ganho de Informação (*Information Gain*)
  - *Impureza* ou incerteza de um nó pode ser medida através da *Entropia*

$$Ent(C,D) = -\sum_{c_i} \frac{\left|D_{[C=c_i]}\right|}{|D|} * \log_2 \frac{\left|D_{[C=c_i]}\right|}{|D|}$$

  -
  - Propriedades da Entropia:
    - Se todos os exemplos de D são da mesma classe então entropia assume valor mínimo
      - *Ent(C,D) = 0*
    - Se todos as classes têm o mesmo número de exemplos em D então entropia assume valor máximo

Árvores de Decisão – Critérios de Separação

- Ganho de Informação (*Information Gain*)
  - O ganho de um atributo/teste é definido pela *redução de Entropia* proporcionada após a separação dos exemplos do nó

$$InfoGain(a, C, D) = Ent(C, D) - \sum_{v_i} \frac{|D_{[a=v_i]}|}{|D|} * Ent(C, D_{[a=v_i]})$$

Entropia do nó pai

Entropia do nó filho ponderada pelo número de exemplos do nó

Árvores de Decisão
– Critérios de Parada

- Totalidade (ou alternativamente, a maioria) do exemplos do nó pertencem a mesma classe
- Profundidade máxima para o nó
- Número mínimo de exemplos no nó
- Ganho pouco significativo no critério de separação

  – Obs.: valores definidos como *parâmetros* do aprendizado

Árvores de Decisão - Exemplo

Day	Outlook	Temp.	Humit.	Wind	Play
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Árvores de Decisão - Exemplo

- Raíz: [9+; 5-]
  - Entropia = - 9/14*$\log_2$(9/14) - 5/14*$\log_2$(5/14) = 0.940
- Considerando teste com atributo Outlook
  - Outlook = Sunny: [2+;3-]
    - Entropia = - 2/5*$\log_2$(2/5) - 3/5*$\log_2$(3/5) = 0.971
  - Outlook = Overcast: [4+;0-]
    - Entropia = - 4/4*$\log_2$(4/4) - 0/4*$\log_2$(0/4) = 0.0
  - Outlook = Rain: [3+;2-]
    - Entropia = - 3/5*$\log_2$(3/5) - 2/5*$\log_2$(2/5) = 0.971
  - Média: 5/14*0.971 + 4/14*0.0 + 5/14*0.971 = 0.694
  - Ganho de Informação: 0.940 - 0.694 = 0.246

Árvores de Decisão - Exemplo

- Considerando os outros atributos:
  - Ganho(Outlook, D) = 0.246
  - Ganho(Humit., D) = 0.151
  - Ganho(Wind, D) = 0.048
  - Ganho(Temp., D) = 0.029

  - Atributo Outlook é o escolhido na raíz

Árvores de Decisão - Exemplo

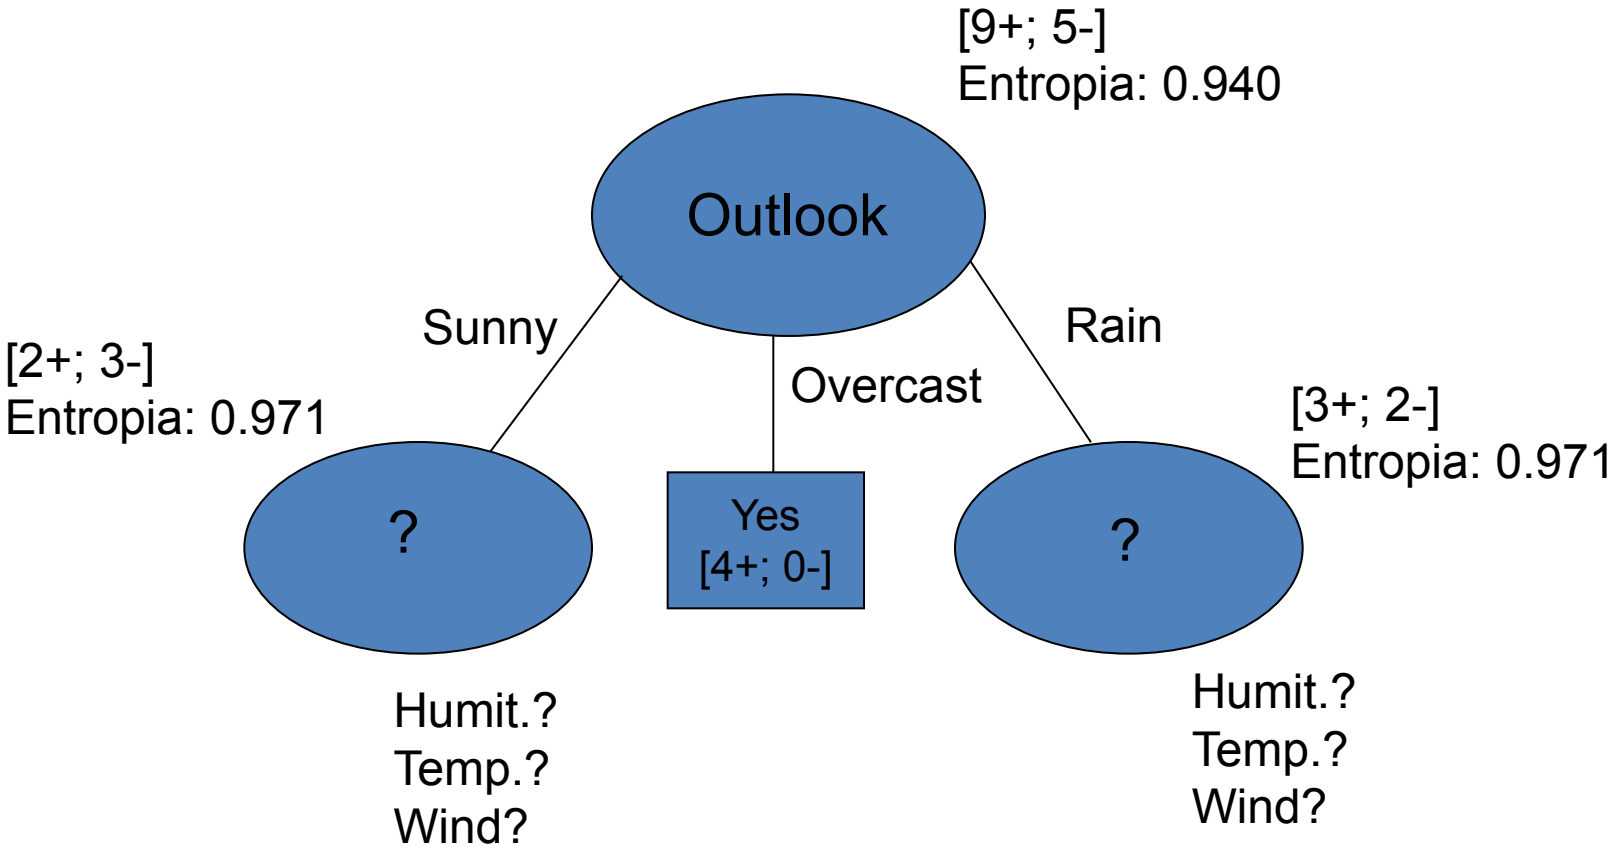

Outro exemplo: Iris Dataset

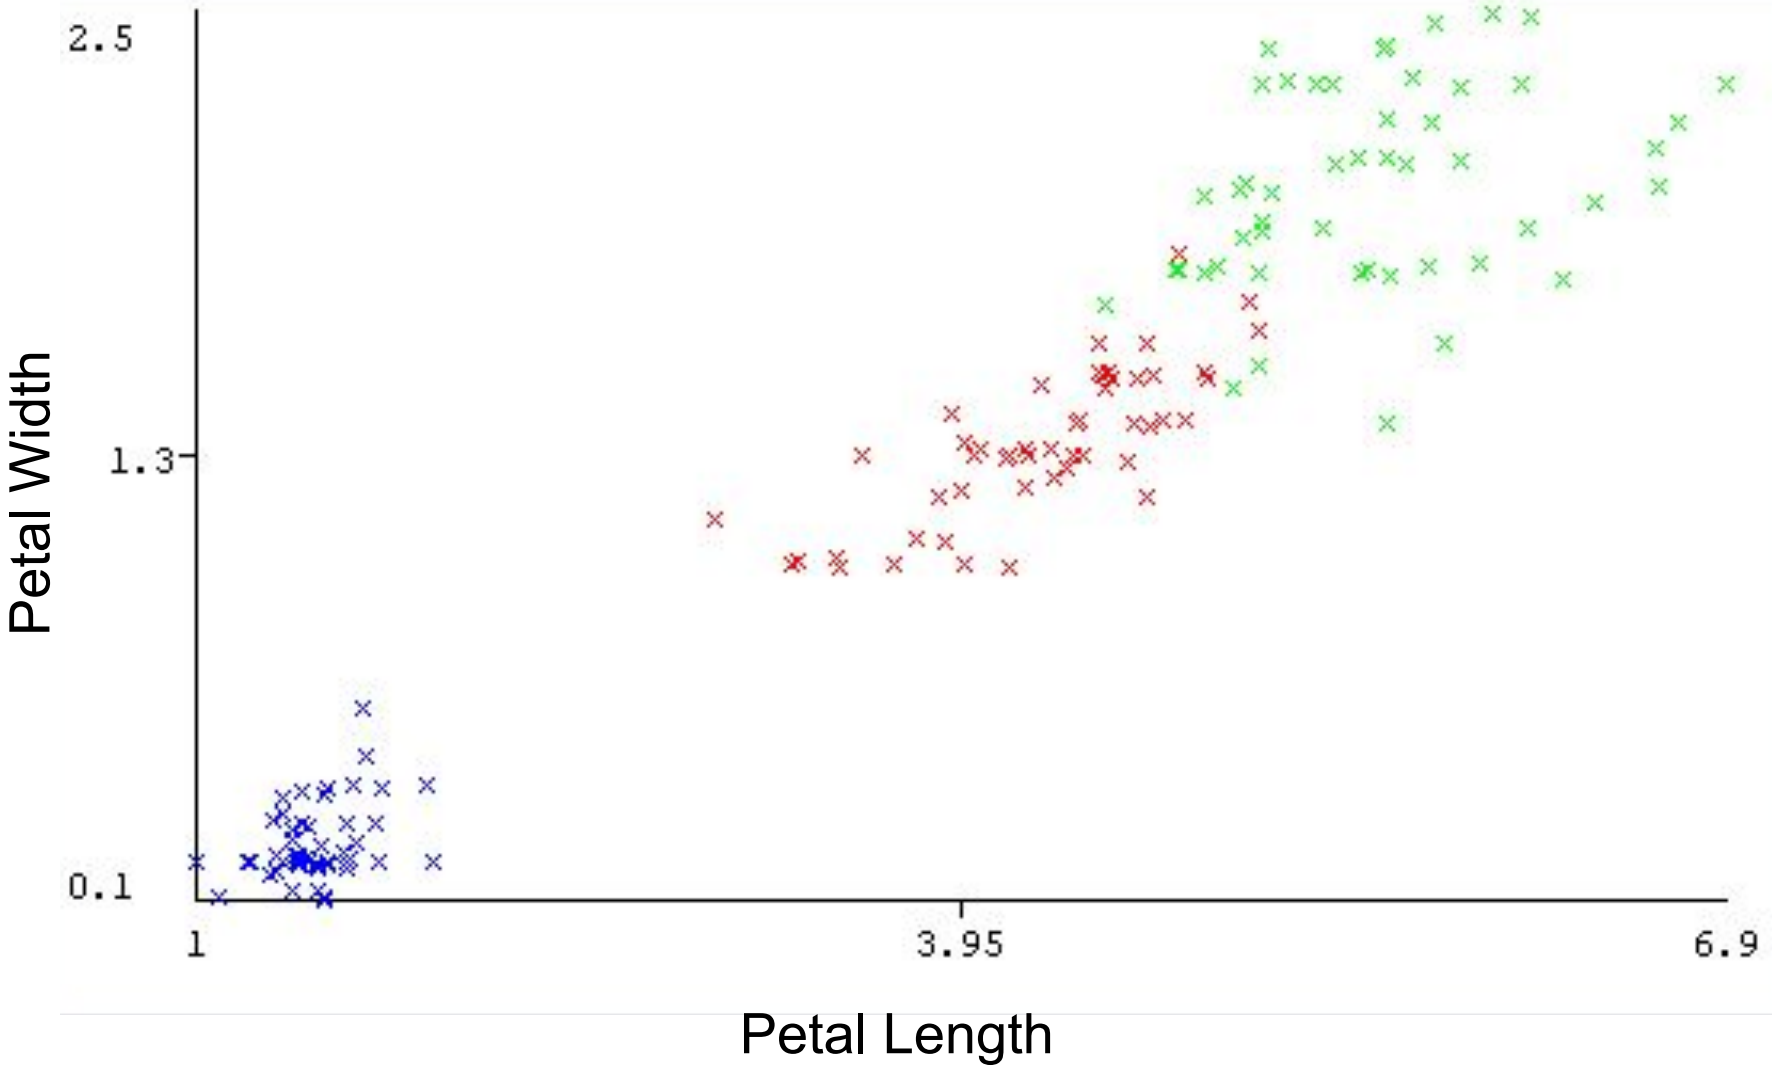

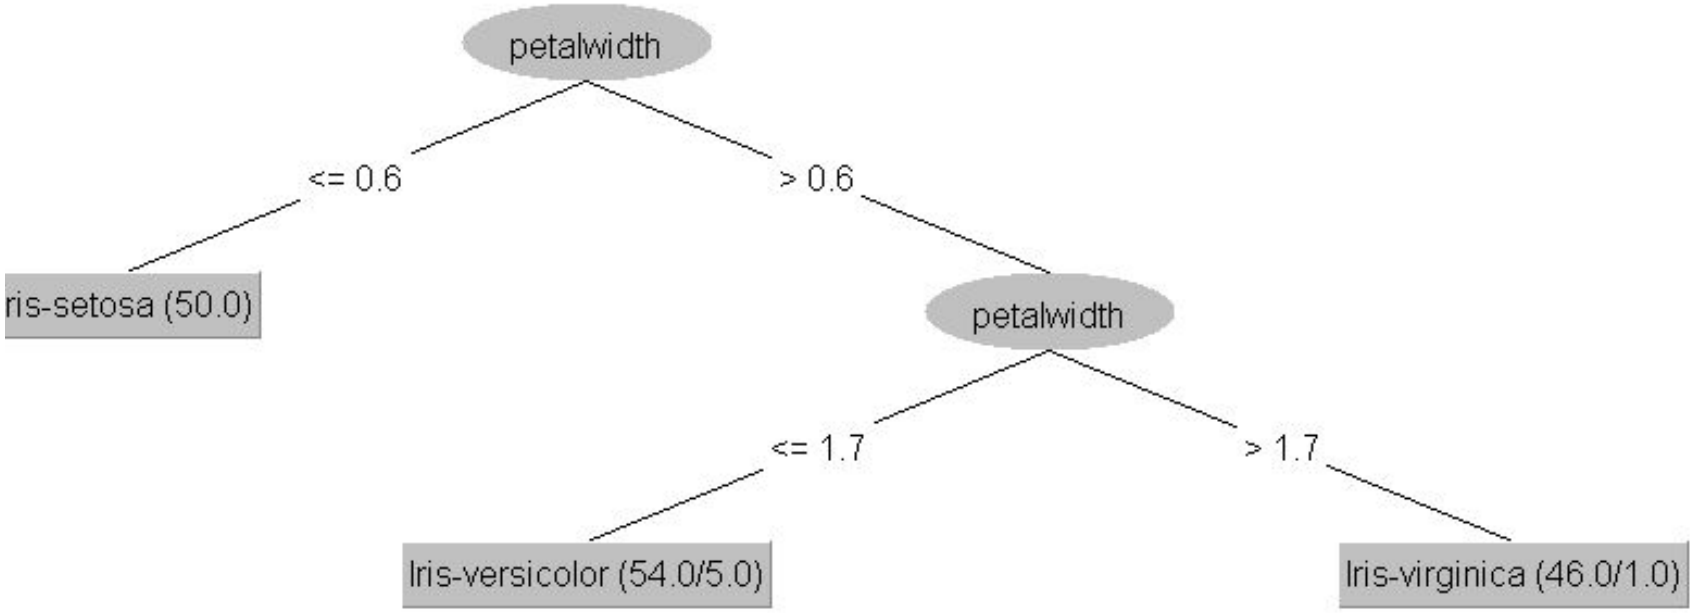

WEKA J48 com número mínimo de instâncias por nó terminal igual a 10

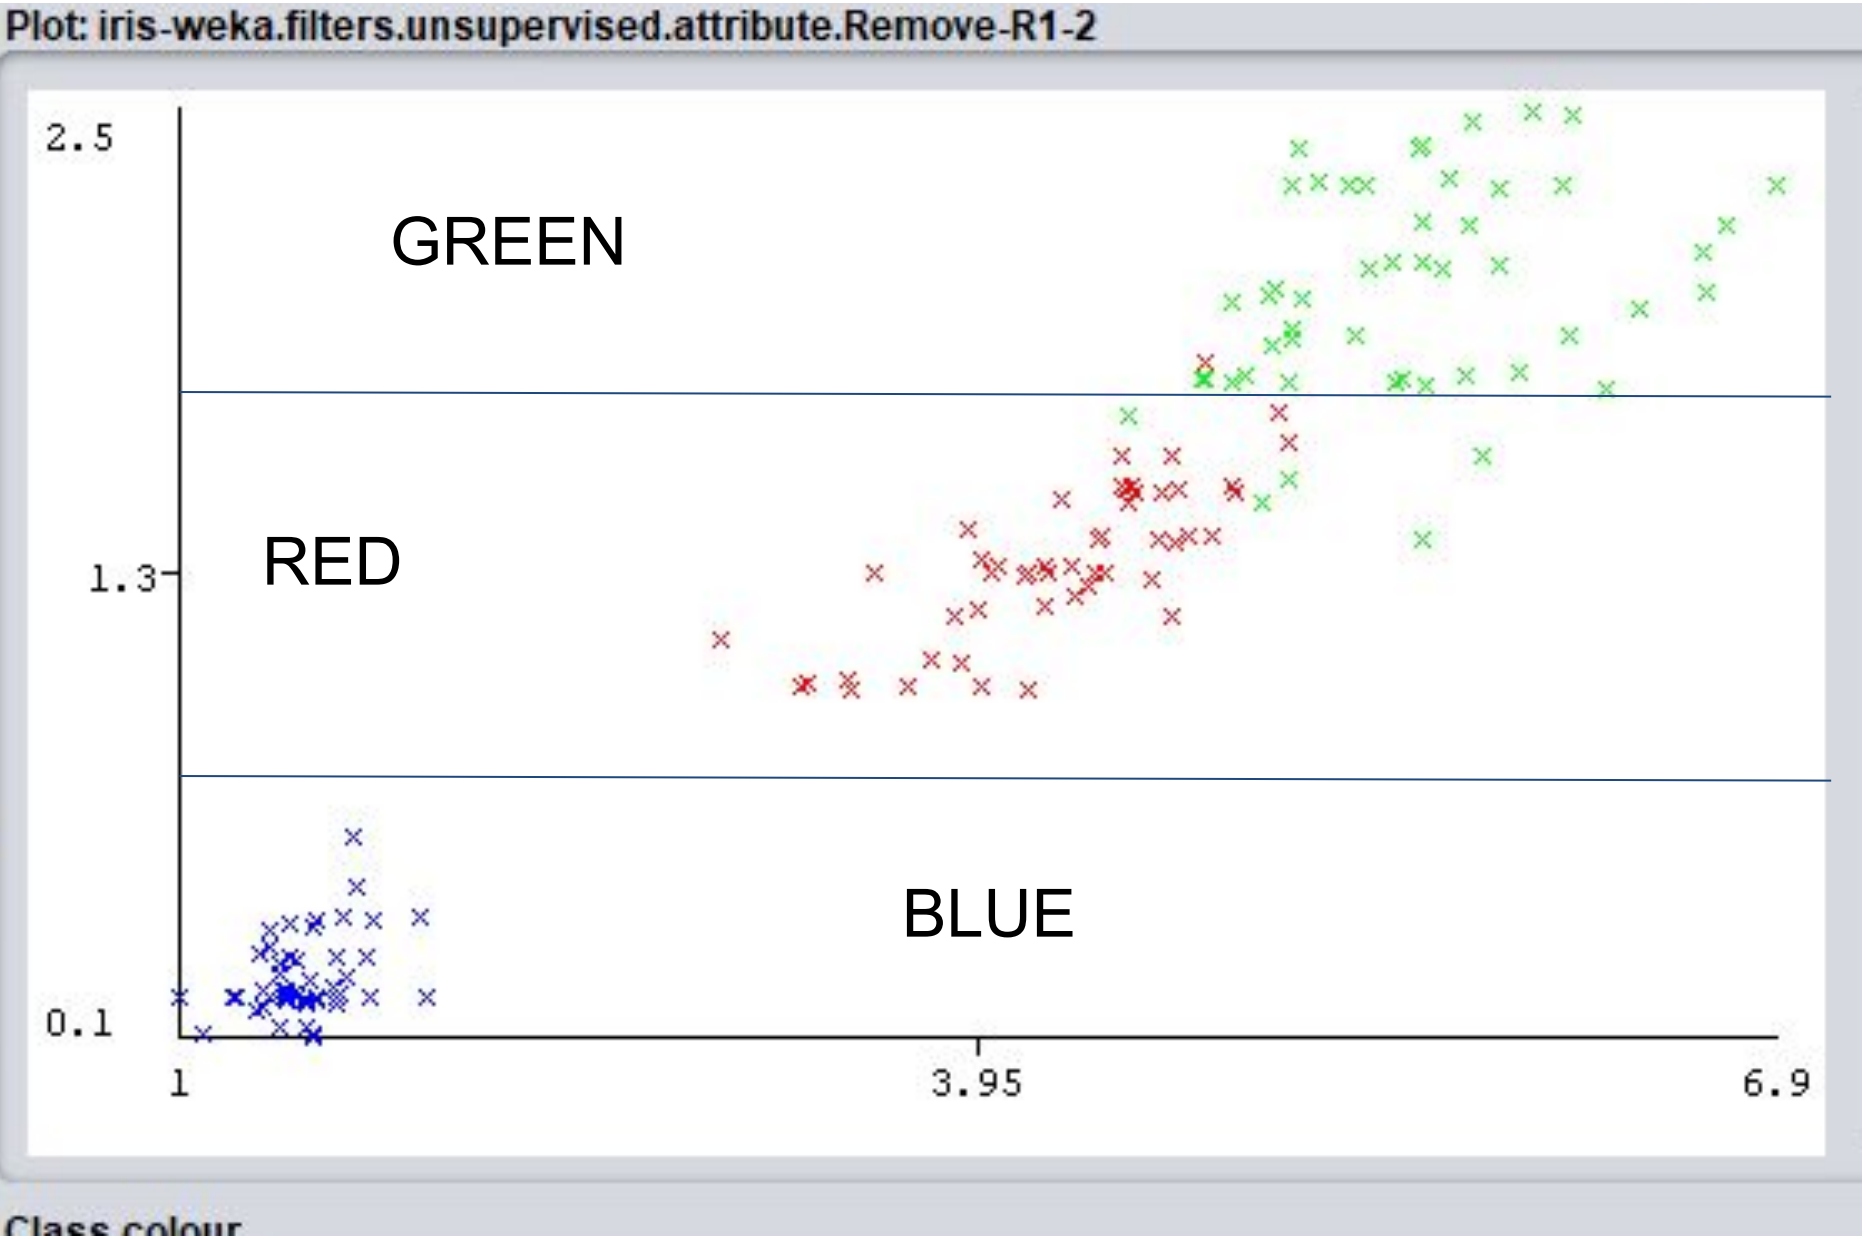
Plot: iris-weka.filters.unsupervised.attribute.Remove-R1-2
2.5
GREEN
RED
1.3
BLUE
0.1
1
3.95
6.9
Class colour

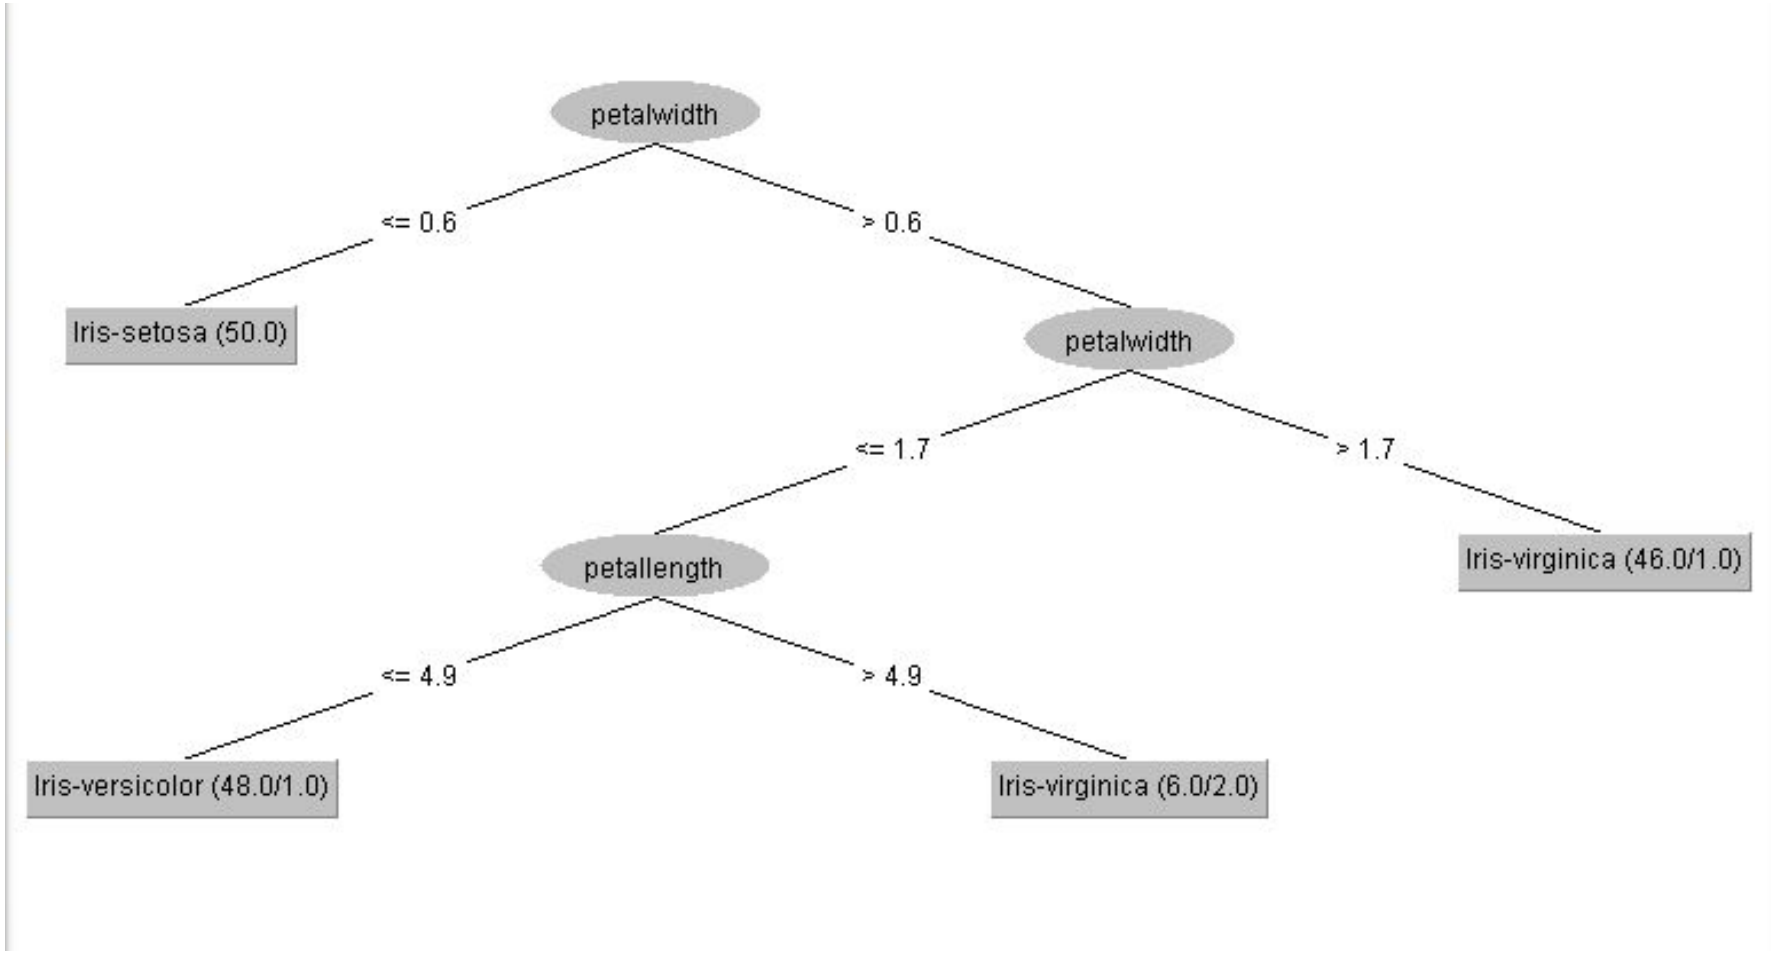

WEKA J48 com número mínimo de instâncias por nó terminal igual a 5

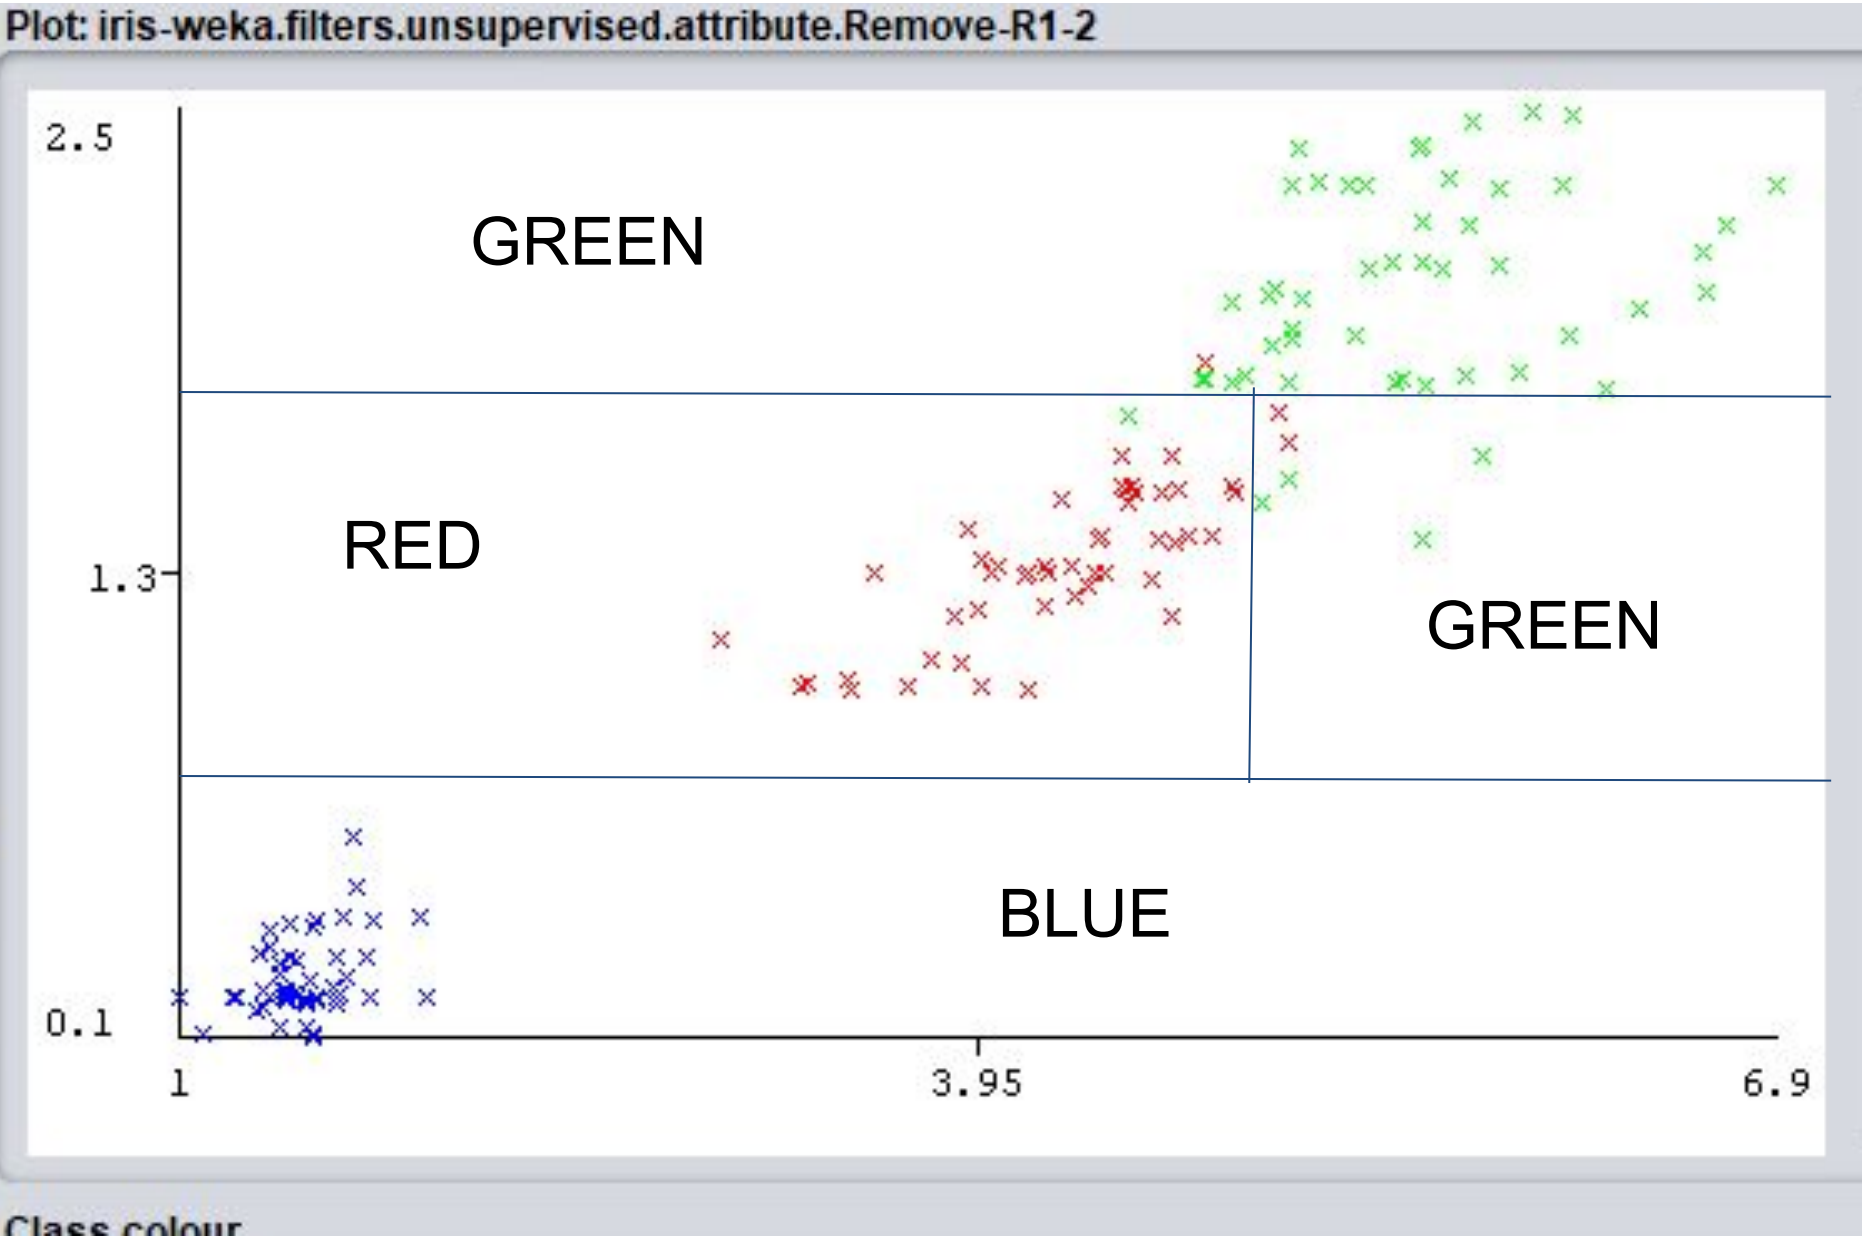
Plot: iris-weka.filters.unsupervised.attribute.Remove-R1-2
2.5
1.3
0.1
1
3.95
6.9
GREEN
RED
GREEN
BLUE
Class colour

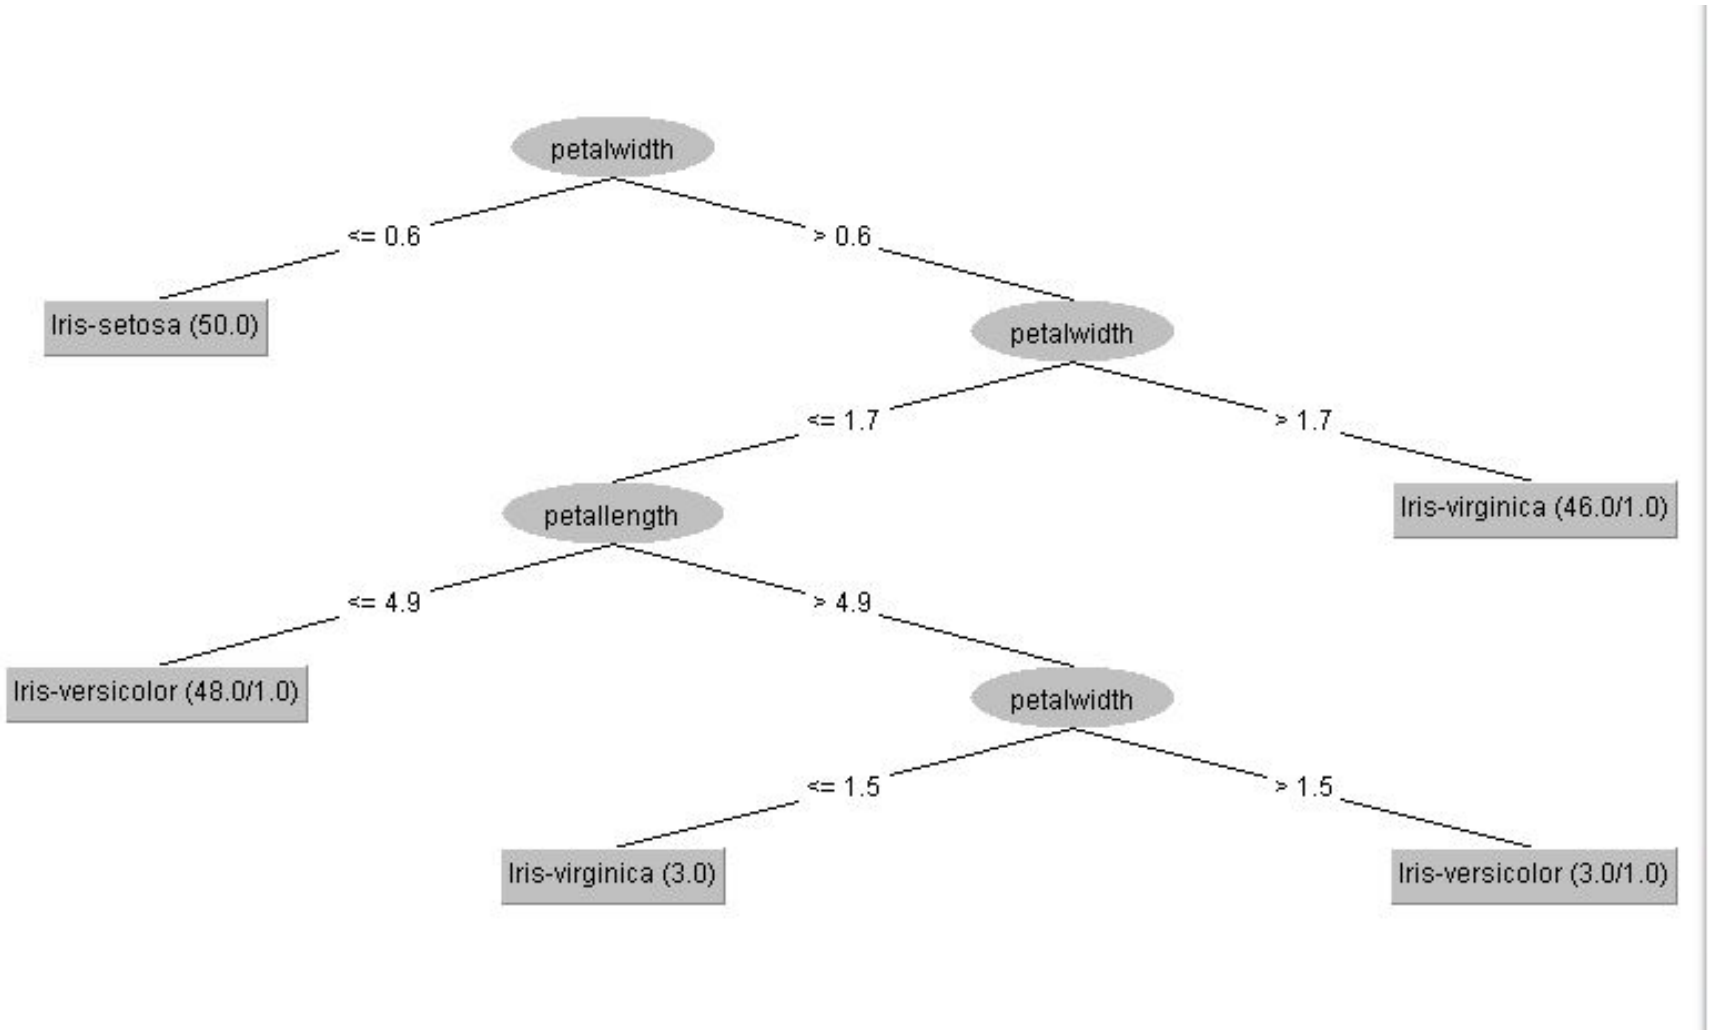

WEKA J48 com número mínimo de instâncias por nó terminal igual a 3

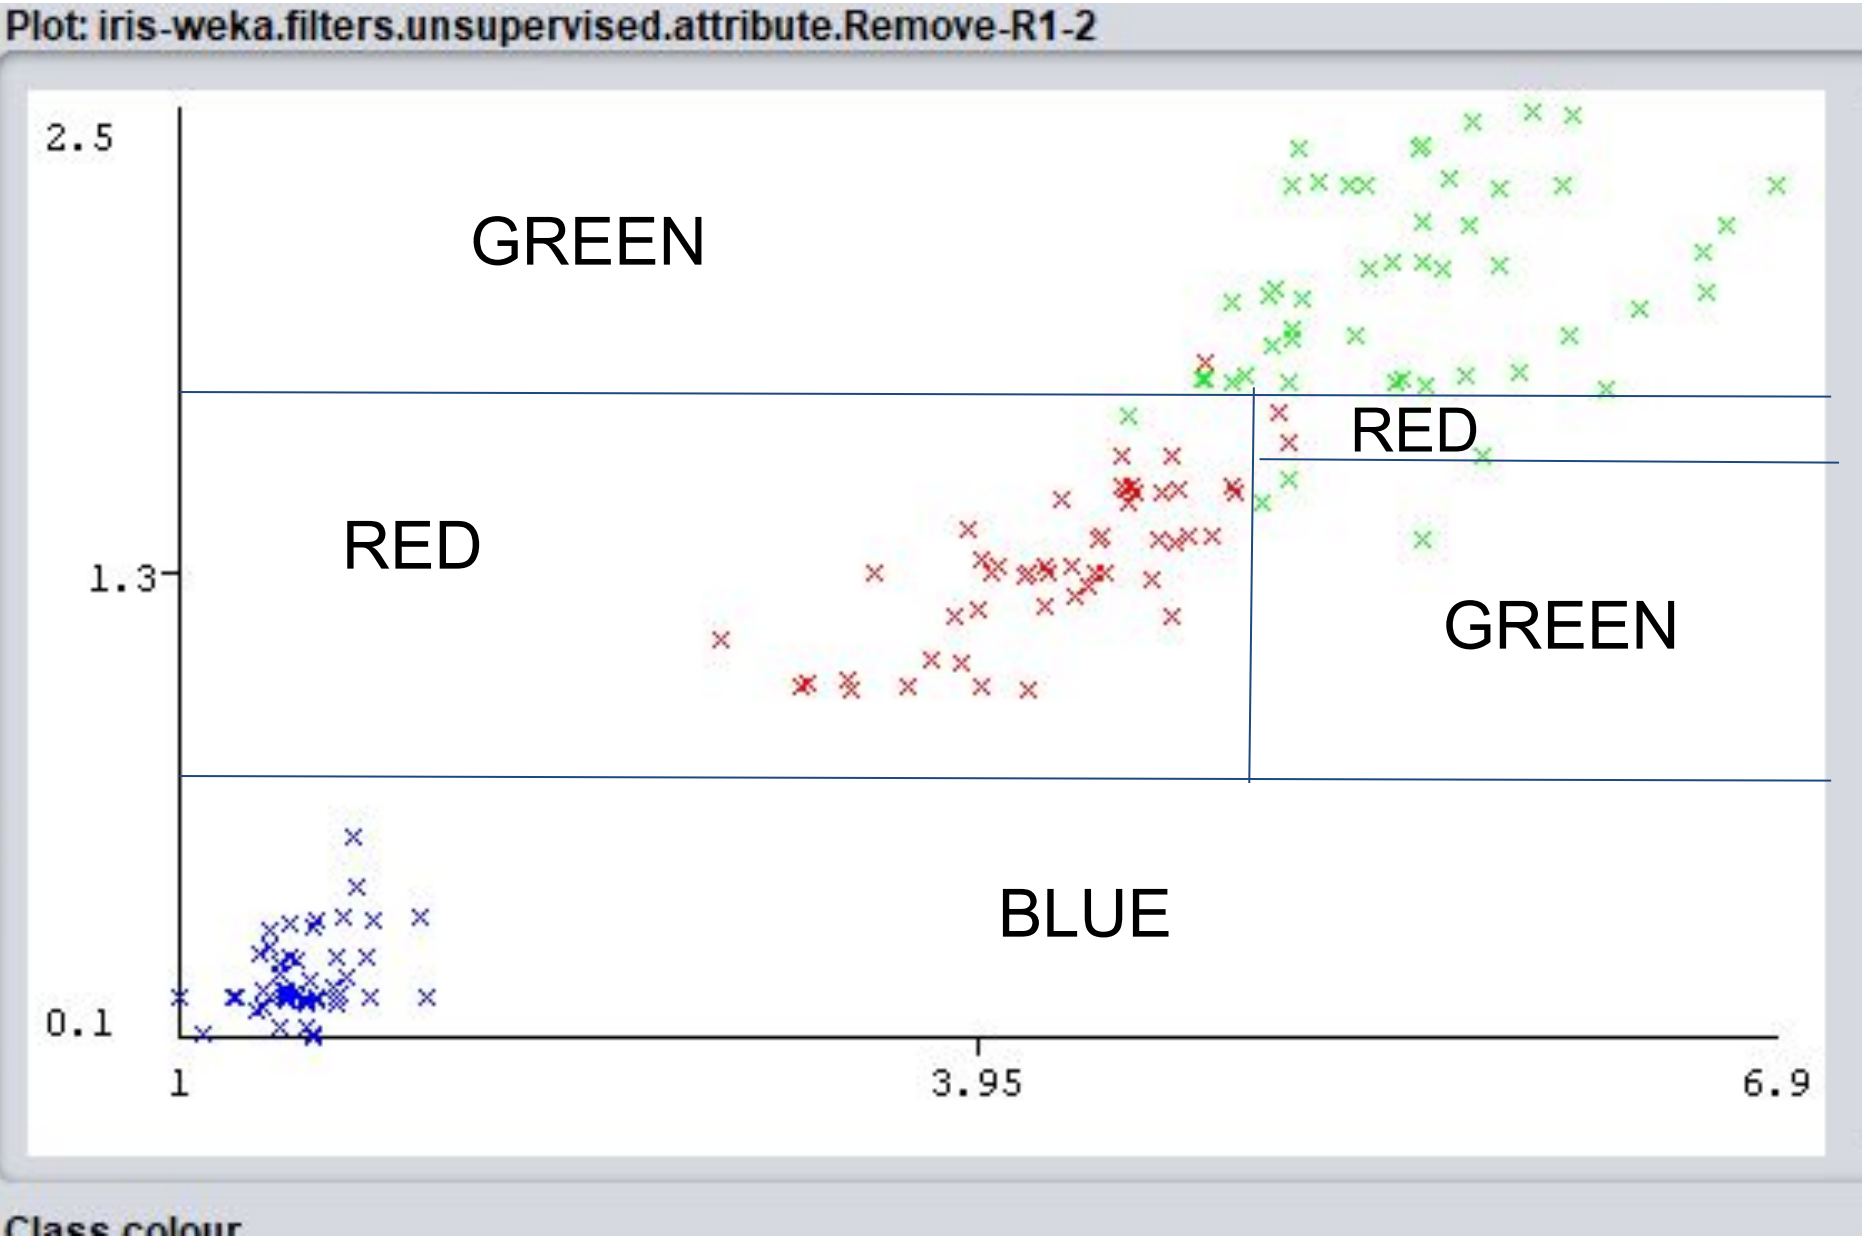
Plot: iris-weka.filters.unsupervised.attribute.Remove-R1-2
2.5
1.3
0.1
1
3.95
6.9
GREEN
RED
RED
GREEN
BLUE
Class colour

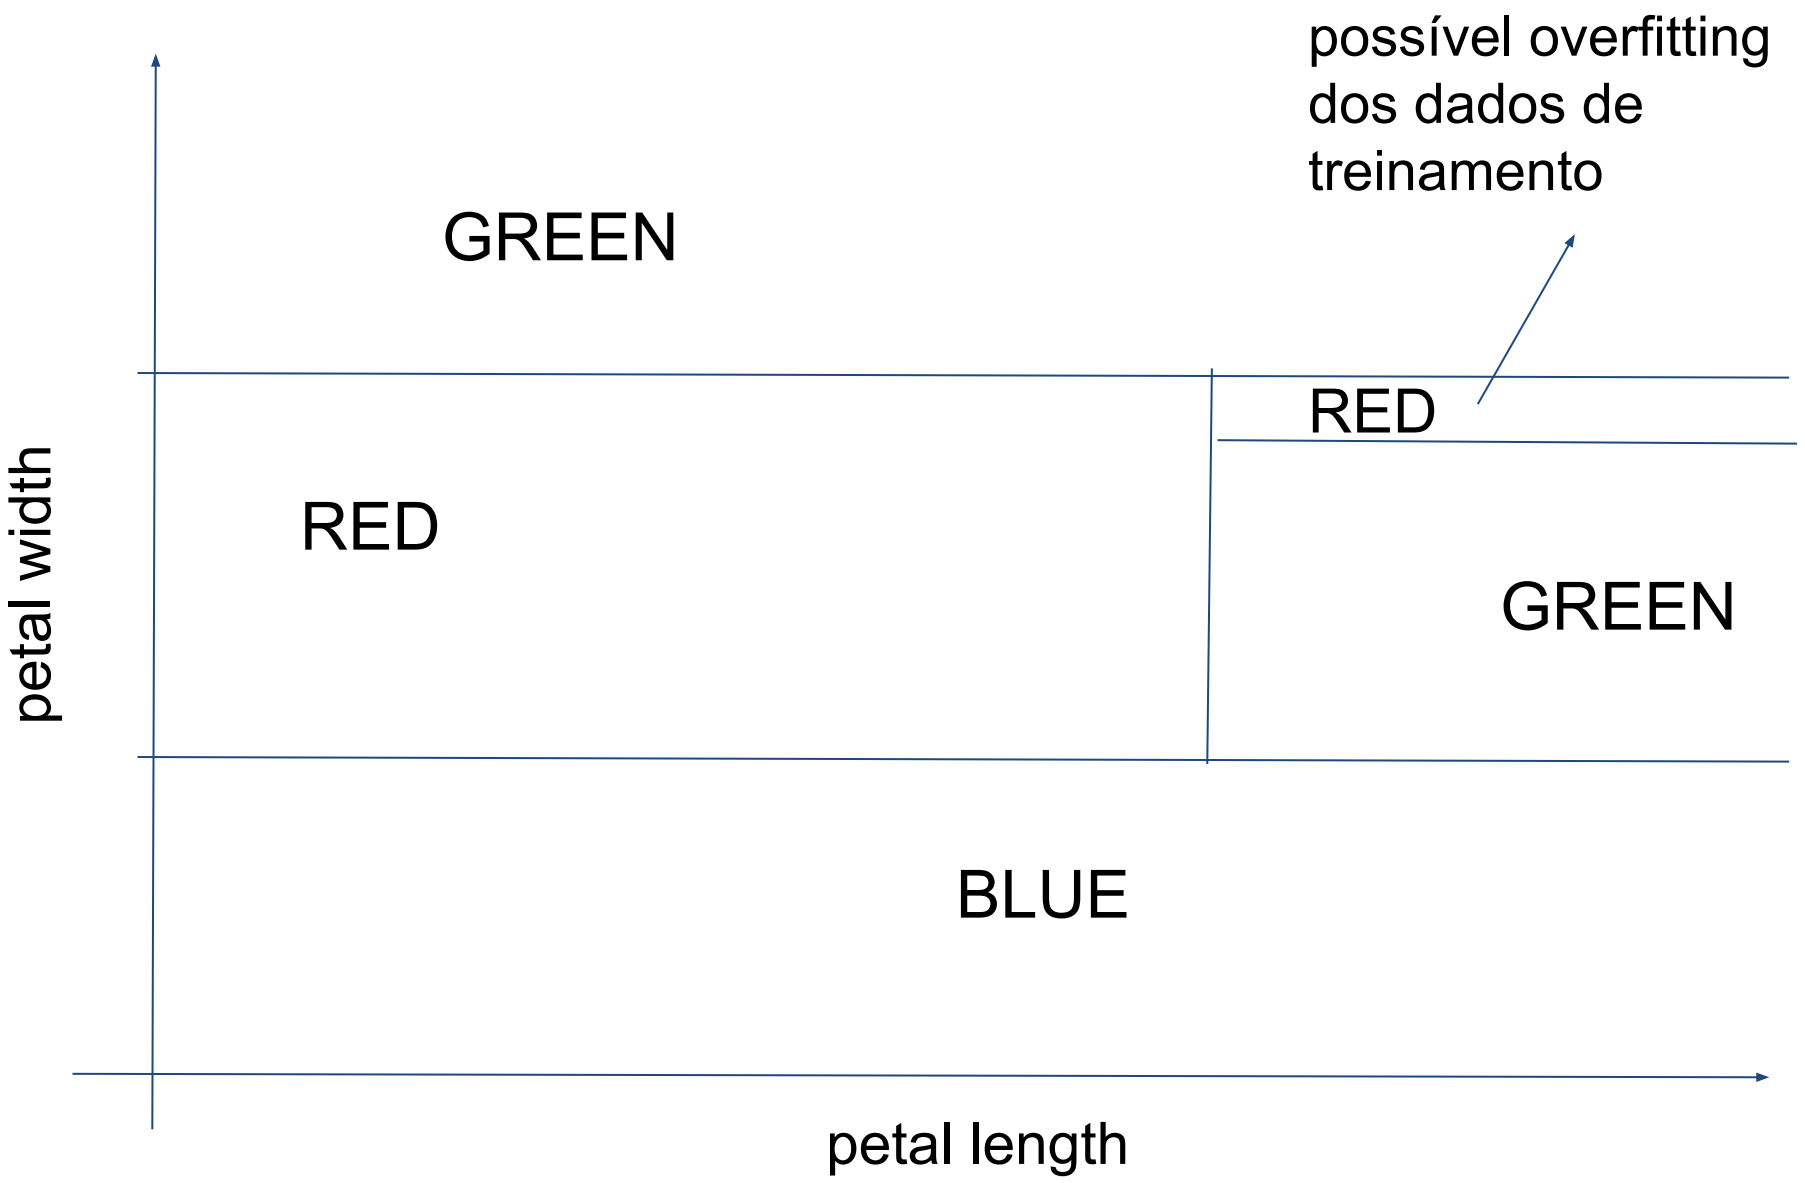
possível overfitting
dos dados de
treinamento
GREEN
RED
RED
GREEN
BLUE
petal width
petal length

Árvores de Decisão
- Discussão

- Vantagens:
  - Geram modelos dos dados (i.e., método *eager*)
  - Conhecimento interpretável
  - Pouca sensibilidade a atributos irrelevantes
    - Uma vez que implementam seleção de atributos

- Desvantagens:
  - Em geral, menos precisos comparados com algoritmos como redes neurais e SVMs
  - Superfícies muito simples de decisão

Árvores de Decisão em R

- Vários pacotes: Rpart, Party,...

- Exemplo: Party

```
> library(party)
> data(iris)
> model = ctree(Species~ Petal.Length + Petal.Width,
data = iris)
> plot(model)
```

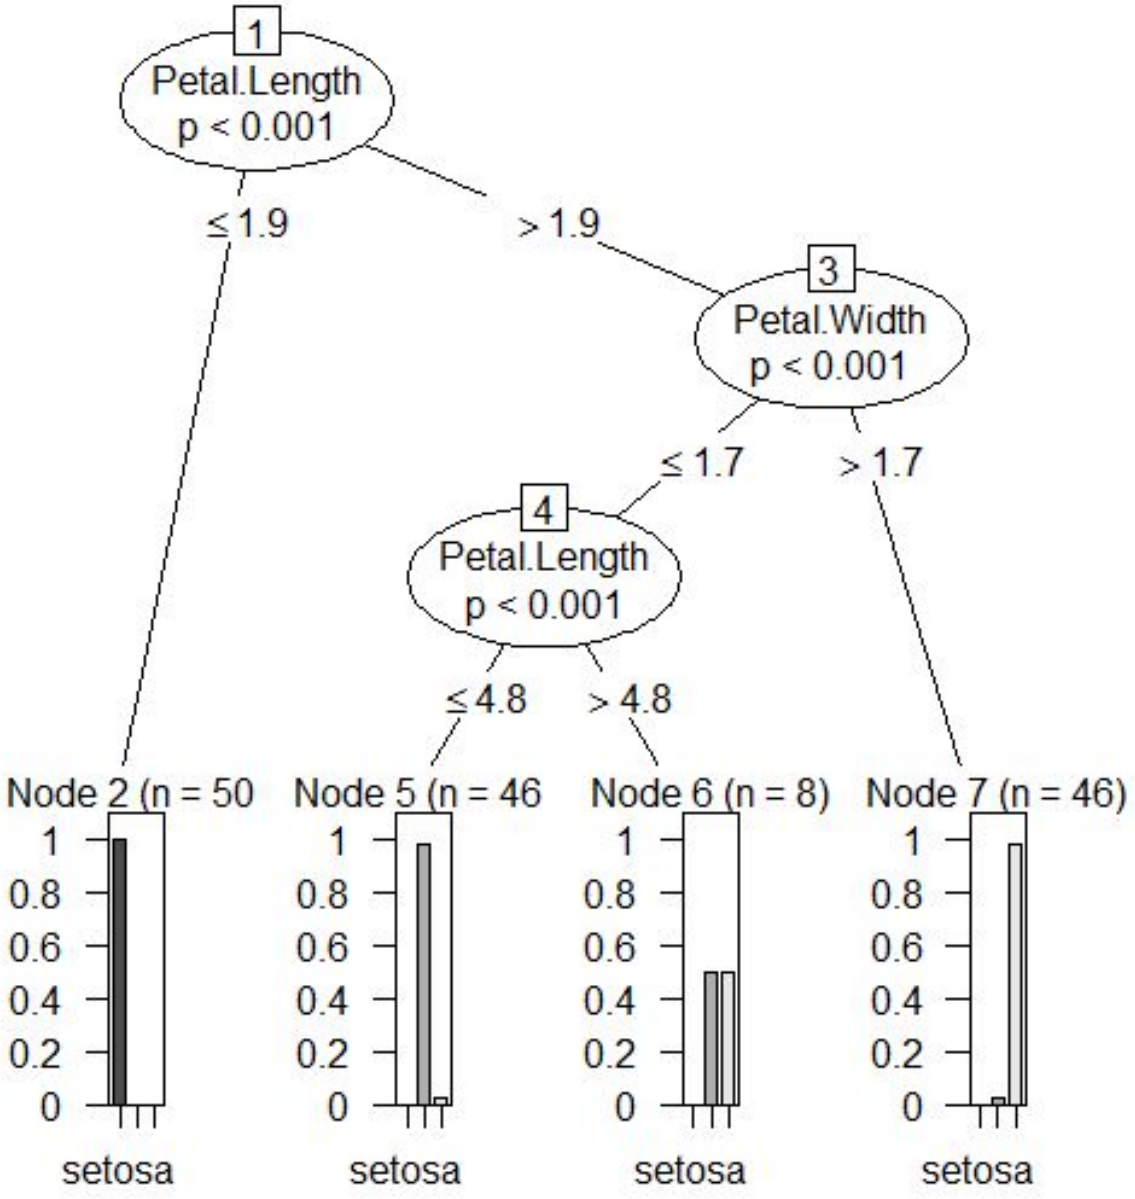
1
Petal.Length
p < 0.001
≤ 1.9
> 1.9
3
Petal.Width
p < 0.001
≤ 1.7
> 1.7
4
Petal.Length
p < 0.001
≤ 4.8
> 4.8
Node 2 (n = 50
Node 5 (n = 46
Node 6 (n = 8)
Node 7 (n = 46)
1
0.8
0.6
0.4
0.2
0
setosa
setosa
setosa
setosa

Árvores de Decisão em R

- Arguments (Parâmetros): ctree_control

```
> model = ctree(Species~., data = iris,
controls = ctree_control(minsplit = 10,maxdepth=1))
> plot(model)
```

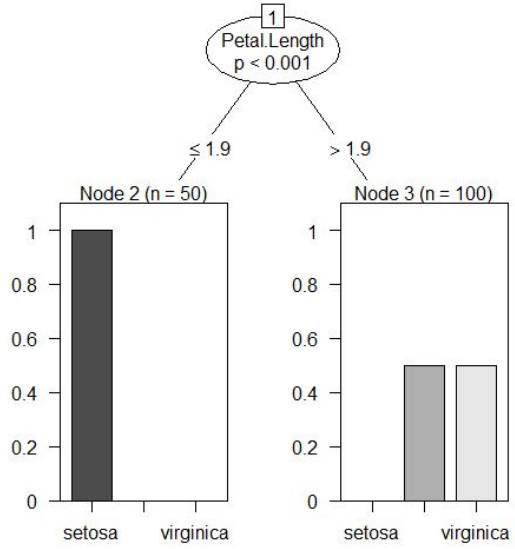

Random Forests

- Variação de árvores de decisões muito mais poderosa

- Comitê de árvores de decisão é treinado
  - Pequenas árvores geradas com conjuntos de atributos e conjuntos de exemplos diferentes

Random Forests - Treinamento

- Construa N árvores de decisão:
  - Passo 1: Selecione aleatoriamente um subconjunto pequeno de atributos
  - Passo 2: Faça uma amostragem bootstrap do conjunto de treinamento
    - I.e.: reamostragem com reposição
  - Passo 3: Gerar árvore de decisão

- Resultado: N árvores de decisão (o comitê)
  - Em geral bem fracas globalmente

Random Forests - Uso

- Dado um exemplo de teste
  - Colete as respostas das N árvores de decisão
  - Contar os votos dados a cada classe

- Resposta final:
  - Classe majoritária entre as respostas do comitê

Ver RandomForest no WEKA

Referências

- T. Mitchell, *Machine Learning*, Cap. 3, 1997.
- I. Witten, E. Frank, 2000. *Data Mining – Practical Machine Learning Tools and Techniques with Java Implementations*.
- M. Monard, J. Baranauskas, Indução de Regras e Árvores de Decisão, *Sistemas Inteligentes*, Cap. 5, 2005.
- J. R. Quinlan, Induction of Decision Trees, *Machine Learning*, Vol.1, N.1, 1986.