Extração e Seleção de Atributos

Ricardo Prudêncio

Introdução

- A eficiência de uma solução depende em muitos casos do tamanho do problema
- Dimensão de um problema de aprendizado
 - Número de atributos
 - Número de exemplos de treinamento
- A dimensão de um problema de aprendizado interfere em muitos casos na:
 - qualidade das respostas (precisão) dos algoritmos
 - e no custo do aprendizado

Redução de Dimensionalidade

Tarefas:

- Redução do número de atributos
- Redução do número de exemplos

Objetivos

- Diminuir o custo do aprendizado
- Aumentar o desempenho preditivo do algoritmo
- Gerar modelos compactos mais fáceis de interpretar

Redução de Atributos

 Em geral, espera-se que todos os atributos sejam relevantes porém nem sempre é possível garantir isso

 Além disso, alguns atributos são redundantes e assim poderiam ser eliminados

- Objetivo:
 - Definir conjunto de atributos que sejam relevantes e não-redundantes

Redução de Atributos

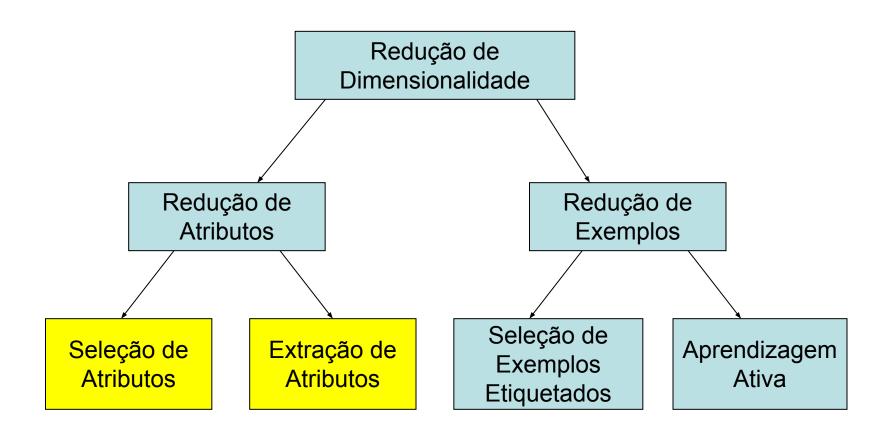
- Abordagens
 - Seleção X Extração de Atributos
- Seleção de atributos:
 - Escolha de um sub-conjunto de atributos relevantes dentre os atributos disponíveis
 - E.g., Filtros e Wrappers
- Extração de atributos:
 - Criação de novos atributos a partir da combinação dos atributos existentes
 - E.g., PCA

Redução de Exemplos

 Conjuntos de treinamento também podem apresentar exemplos irrelevantes e redundantes

- Abordagens:
 - Seleção de exemplos etiquetados
 - Seleção de exemplos não-etiquetados
 - Aprendizagem Ativa

Redução de Dimensionalidade



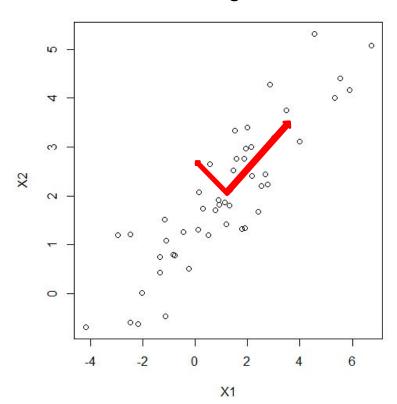
Extração de Atributos

- Criação de atributos relevantes através da combinação dos atributos originais
- Muito usado para análise exploratória de dados
- Diversas técnicas
 - PCA, ICA, SVD, FPCA,...

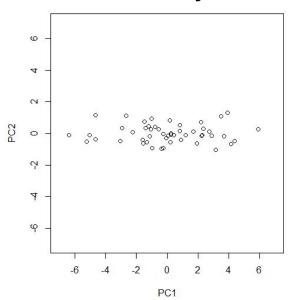
Principal Component Analysis

- Cada nova dimensão é uma combinação linear das variáveis originais dos dados
- Cada nova dimensão é chamada de componente principal
- Componentes principais são ordenados de forma a explicar a variância dos dados

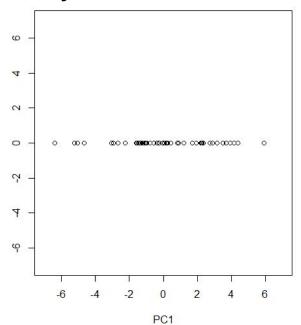
Dados Originais



Transformação PCA



Redução de Dimensionalidade



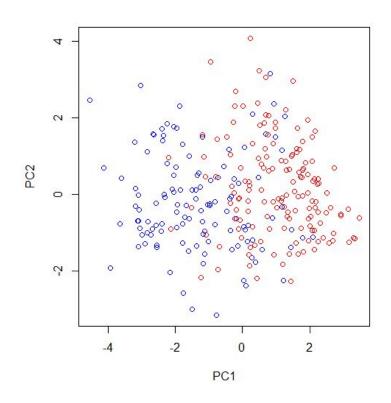
Heart Dataset

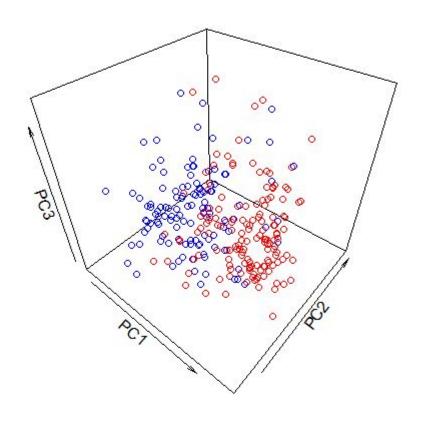
• 13 atributos

Standard deviations:

[1] 1.7450842 1.2679385 1.1140628 1.0773529 1.0061711 0.9532100 0.9087842

[8] 0.8656492 0.8231727 0.7590373 0.6734324 0.6346909 0.5821222



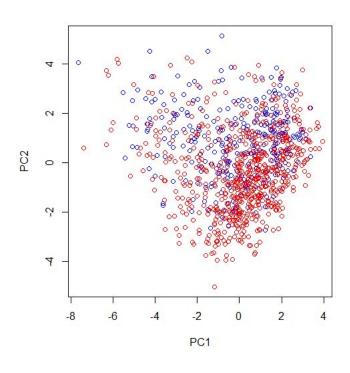


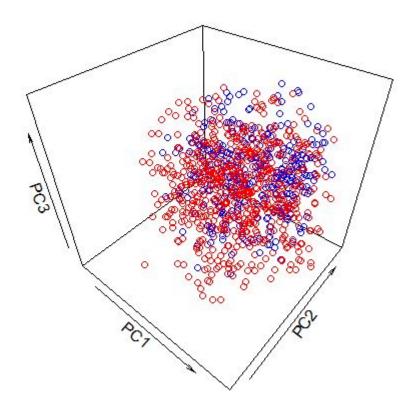
German Dataset

• 59 atributos

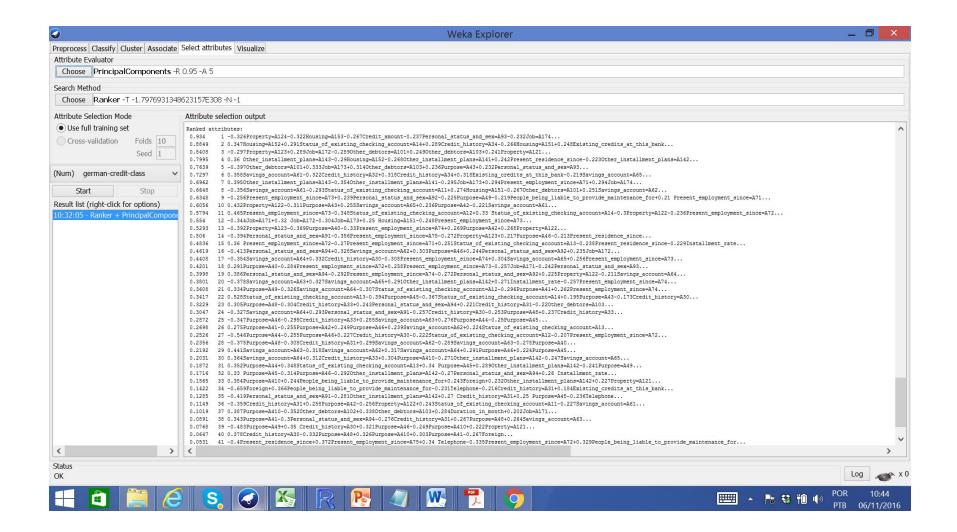
Standard deviations:

[1] 1.973460 1.701656 1.613873 1.560912 1.447674 1.421420 1.406148 1.361314 [9] 1.330906 1.310890 ...





PCA no WEKA



Seleção de Atributos

Filtros

- Atributos são ordenados com base em métricas de relevância e redundância
- Retorna os atributos mais bem orderados

Wrappers

- O desempenho do algoritmo é avaliado para diferentes sub-conjuntos de atributos;
- O melhor sub-conjunto encontrado é retornado;

Seleção de Atributos – Filtros

- Descartam atributos irrelevantes antes do processo de aprendizado
 - I.e., independente do algoritmo
- Caracteristicas gerais dos dados são levadas em consideração para selecionar atributos
 - I.e. dados avaliados com estatísticas descritivas
- Diferentes métricas podem ser usadas para definir relevância de atributos
 - K atributos mais relevantes são retornados

Seleção de Atributos – Filtros

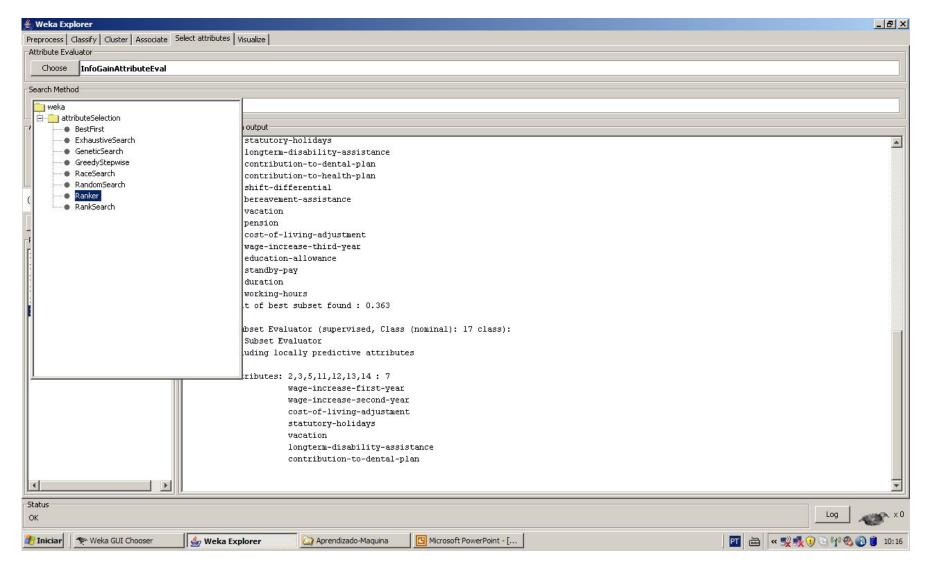
- Exemplos de métricas:
 - InfoGain, GainRatio,... e outras métricas usadas para seleção de atributos em árvores de decisão
 - Correlação entre o atributo avaliado e o atributo classe

Seleção de Atributos – Filtros

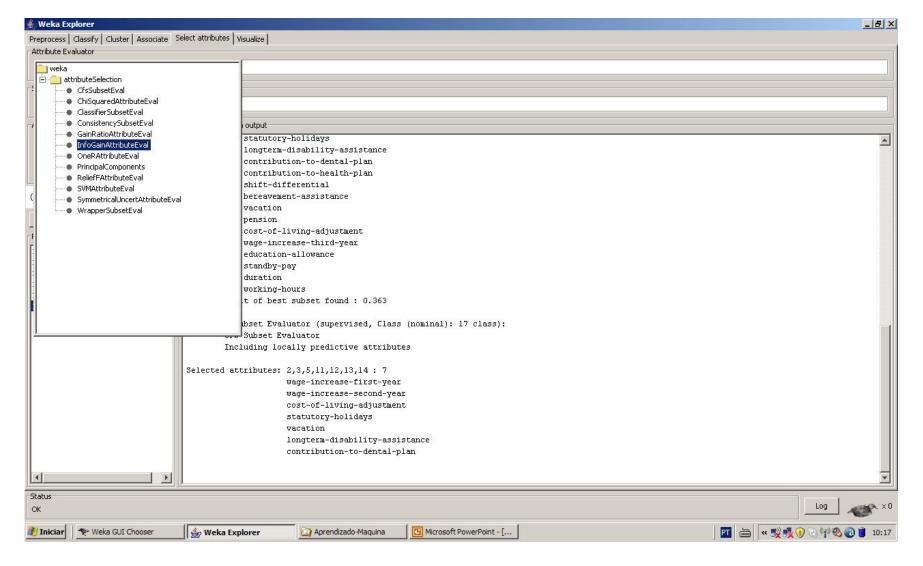
 Em geral, filtros de atributos são leves computacionalmente

- Porém apresenta dificuldades:
 - Nem sempre é fácil definir quantos atributos descartar;
 - Na prática, isso é definido por tentativa-e-erro
 - Não leva em consideração o algoritmo sendo utilizado;

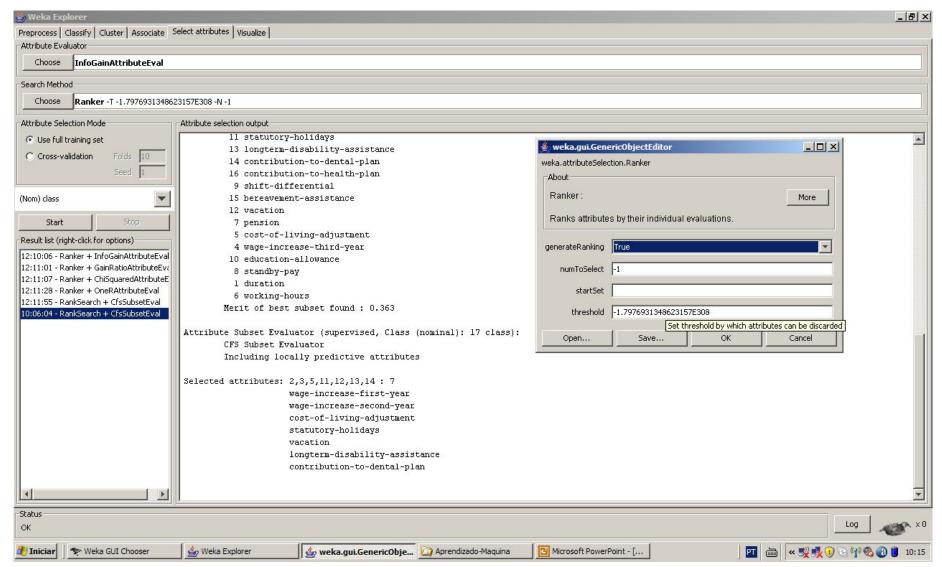
Seleção de Atributos – Filtros (WEKA)



Seleção de Atributos – Filtros (WEKA)



Seleção de Atributos – Filtros (WEKA)



Seleção de Atributos – Wrappers

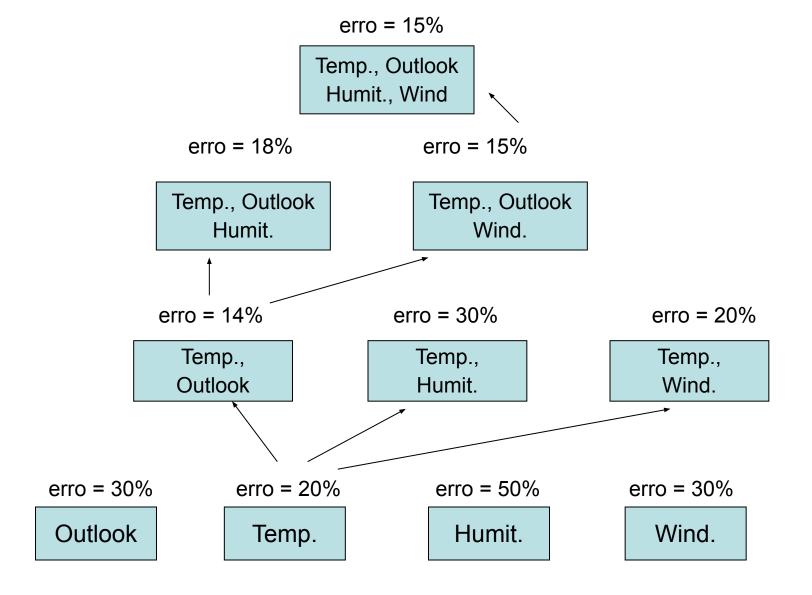
- Wrappers realizam, de fato, uma busca no espaço de sub-conjuntos de atributos
 - Busca exaustiva não é realizada na prática

 São vantajosos em relação aos filtros por considerarem o algoritmo em questão

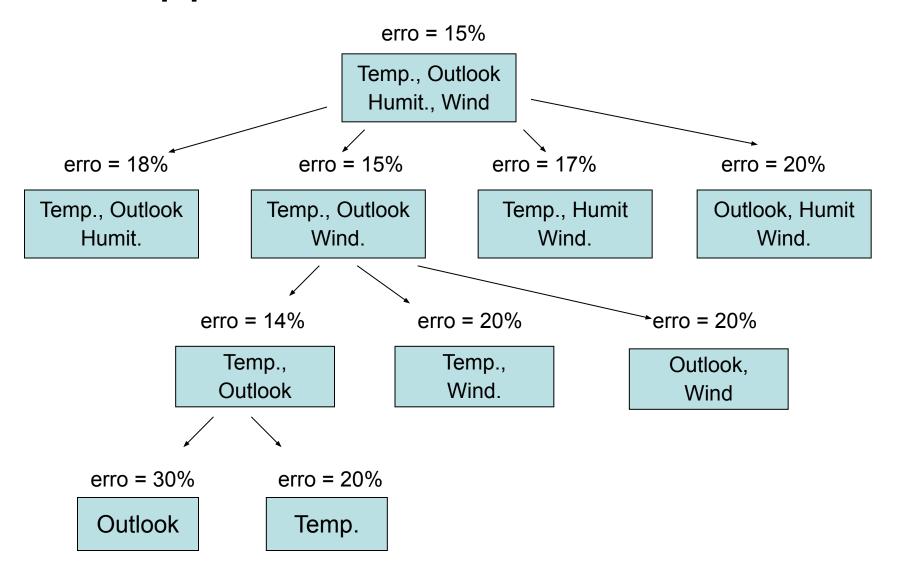
Seleção de Atributos – Wrappers

- Forward-Selection
 - Busca se inicia a partir de sub-conjuntos com um atributo
 - Atributos são adicionados progressivamente
- Backward-Elimination
 - Inicia com o sub-conjunto de todos os atributos;
 - Atributos são removidos progressivamente

Wrappers – Forward-Selection



Wrappers – Backward-Elimination



Seleção de Atributos – Wrappers

Backward-Elimination

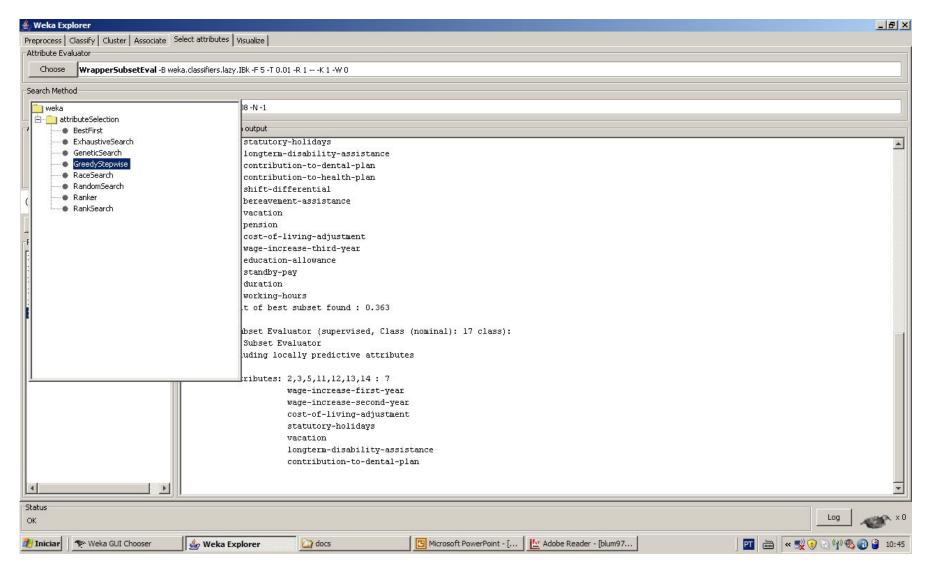
- Em geral, produz melhores resultados em termos de precisão;
- Porém é mais pesado computacionalmente

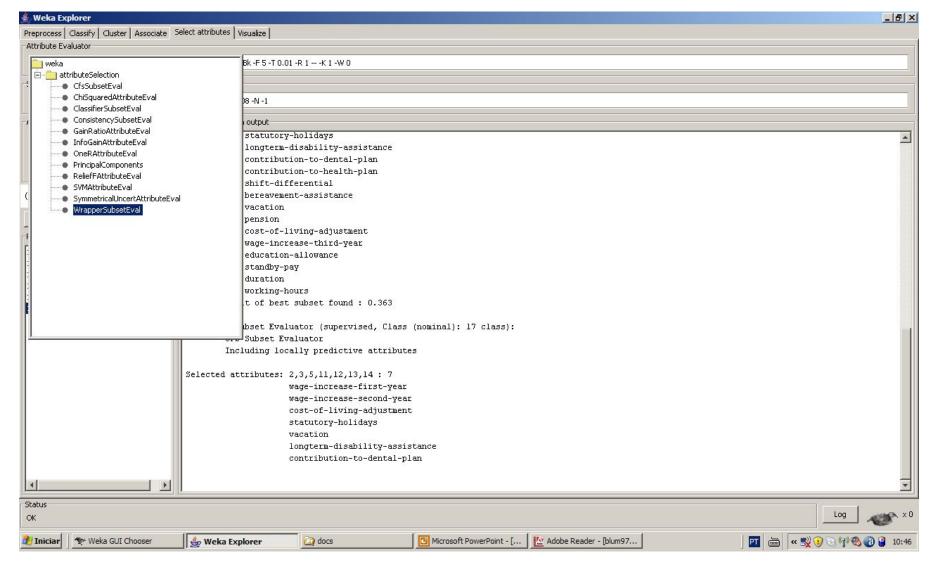
Forward-Selecion

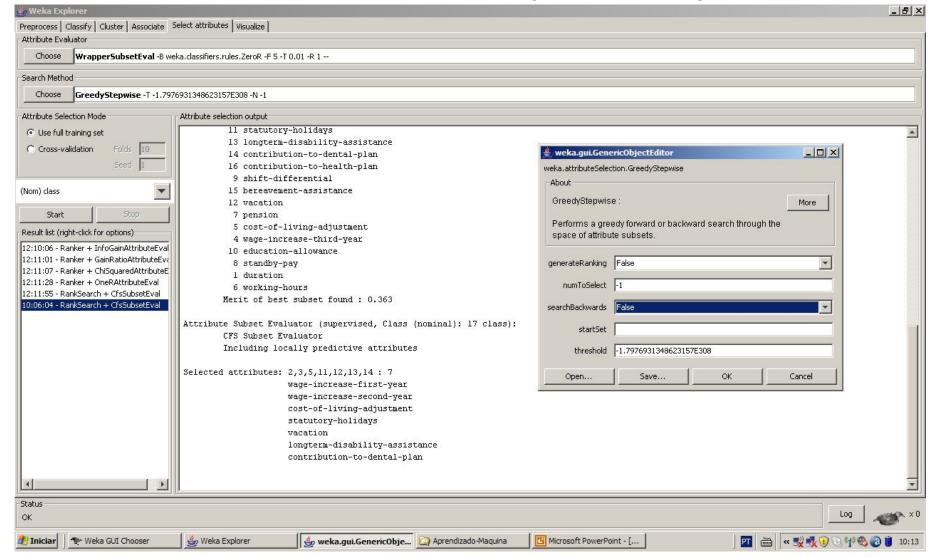
- Tende a produzir sub-conjuntos com menos atributos;
- É capaz de eliminar melhor atributos redundantes

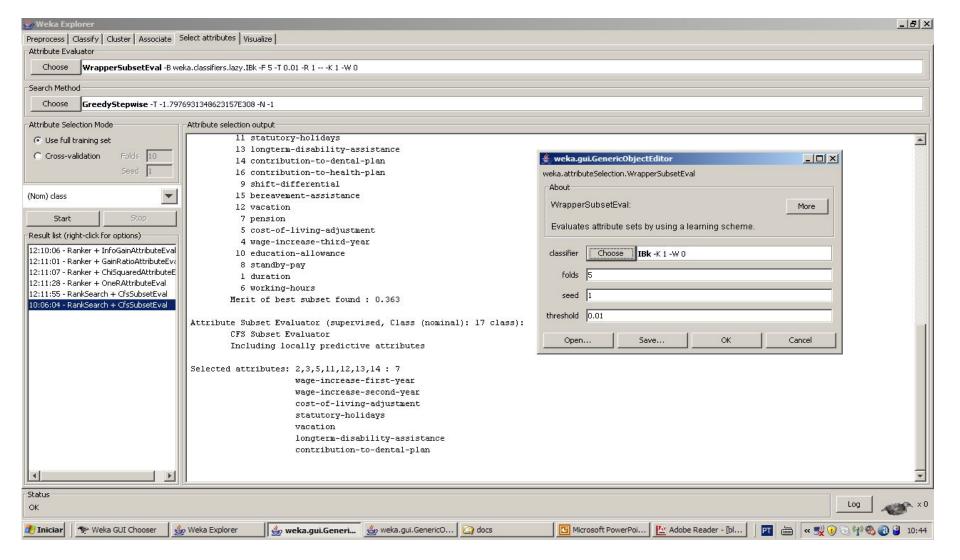
Seleção de Atributos – Wrappers

- Tanto Forward-Selection como
 Backward-Elimination caem em mínimos locais
 - Ambos os algoritmos realizam greedy search
- Diversos algoritmos de busca e otimização podem ser aplicados
 - E.g., Algoritmos Genéticos







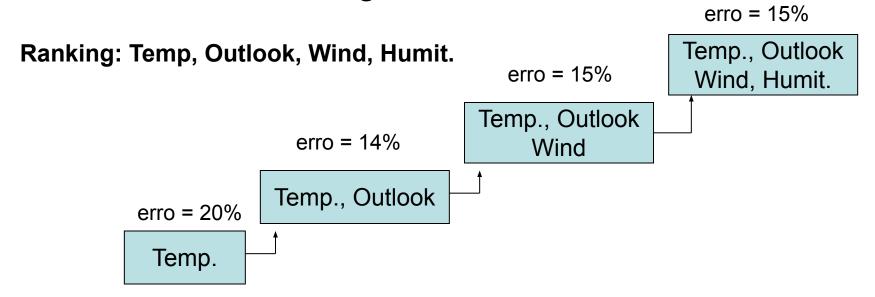


Seleção de Atributos

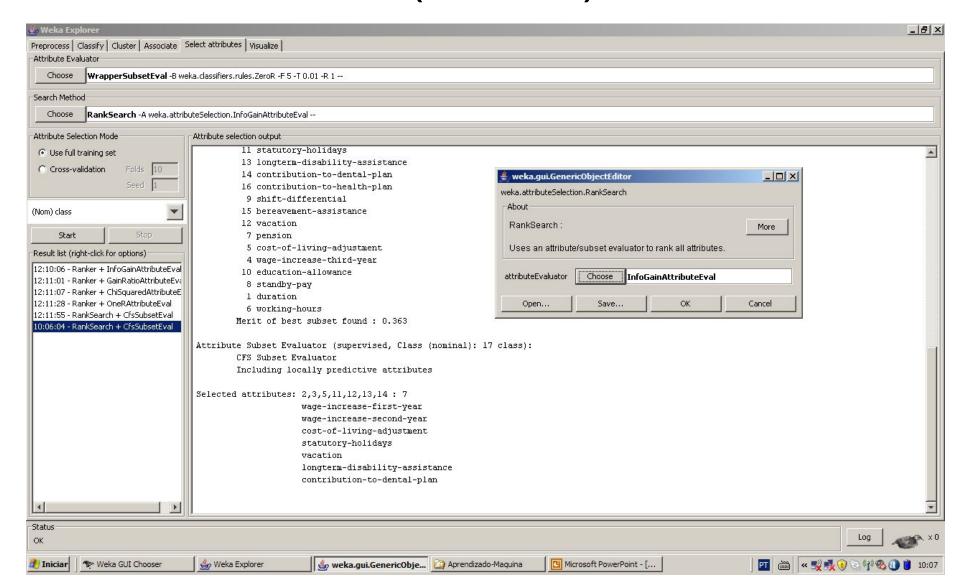
- Busca em espaço de atributos é mais pesado computacionalmente que as técnicas de filtros
- Porém, podemos minimizar esse problema:
 - Utilizando algoritmos de busca mais eficientes (e.g., RankSearch);
 - Utilizando algoritmos mais leves para avaliação dos sub-conjuntos;
 - Combinando com filtros (e.g., usar uma métrica de filtro como medida de avaliação)

Seleção de Atributos

- RankSearch
 - Ordenar atributos com uma métrica de filtro
 - E.g., InfoGain
 - Avaliar sub-conjuntos, inserindo gradualmente os atributos na ordem gerada



Seleção de Atributos – RankSearch (WEKA)



Referências

- A. Blum, P. Langley, Selection of relevant features and examples in machine learning, Artificial Intelligence, 1997.
- R. Kohavi, GH John, Wrappers for feature subset selection, *Artificial Intelligence*, 1997.
- I. Guyon, A. Elisseefi, L. Kaelbling, An Introduction to variable and feature selection, Journal of Machine Learning Research, 2003.